Università degli Studi di Torino

Dipartimento di Informatica



TECNOLOGIE DEL LINGUAGGIO NATURALE

Esercitazioni parte: 2

Budaes Tanaru Riccardo Gabriele

Driza Andrea

Indice

1 Esercitazione 1: Document Similarity e Retrieval (VSM) 2
1.1 Strumenti Utilizzati 2
1.2 Vantaggi e Limitazioni 2
1.3 Discussione dei Risultati 2

2 Esercitazione 2: Word Clustering con Word2Vec 3
2.1 Strumenti Utilizzati 3
2.2 Vantaggi e Limitazioni 3
2.3 Discussione dei Risultati 4

3 Esercitazione 3: N-gram Language Models 5
3.1 Strumenti Utilizzati 5
3.2 Vantaggi e Limitazioni 5
3.3 Discussione dei Risultati 5

4 Conclusioni 5

1 Esercitazione 1: Document Similarity e Retrieval (VSM)

1.1 Strumenti Utilizzati

Per questa esercitazione è stato implementato un sistema di reperimento basato sul **Vector Space Model (VSM)** utilizzando la pesatura **TF-IDF** (*Term Frequency-Inverse Document Frequency*). Il preprocessing del dataset è stato eseguito tramite la libreria **spaCy**:

- **Batch Processing:** Utilizzo di `nlp.pipe` con `batch size=256` per velocizzare l'elaborazione dei documenti.
- **Pipeline Leggera:** Esclusione dei componenti `ner` (Named Entity Recognition) e `parser` per ridurre il carico computazionale, mantenendo solo il `tagger` necessario per una corretta lemmatizzazione.

La ricerca dei documenti più rilevanti è stata calcolata tramite la **similarità coseno** tra il vettore della query e la matrice TF-IDF dei documenti.

1.2 Vantaggi e Limitazioni

- **Vantaggi:** L'approccio basato su spaCy e TF-IDF è estremamente veloce e scalabile. L'uso della lemmatizzazione permette di ricondurre diverse forme flessionali allo stesso termine (es. "sinking" e "sink"), migliorando il richiamo del sistema.
- **Limitazioni:** Il modello soffre di **gap lessicale** e incapacità di gestire la **polisemia**. Poiché il sistema si basa sul matching delle stringhe (lemmatizzate), non è in grado di distinguere tra i diversi significati di una parola se questa compare nello stesso contesto morfologico.

1.3 Discussione dei Risultati

L'ispezione dei risultati ottenuti ha confermato le limitazioni teoriche del modello:

1. **Problema della Polisemia:** Per la query `"stock market crash"`, il sistema ha restituito titoli come *"World's Best Food Markets"* e *"Healthy Picks To Stock Up On Now"*. Questo dimostra che il modello non comprende la differenza semantica tra "stock" inteso come azione finanziaria e "stock" come scorta alimentare.
2. **Overfitting Lessicale:** Per la query `"government budget deficit"`, il primo risultato è stato *"On a Budget? 5 Ways You Can Still Travel the World!"* (Score: 0.3392). Nonostante la query fosse politica, la forte presenza del termine "budget" in articoli di viaggio ha ingannato il modello, che ha dato priorità alla frequenza del termine rispetto alla pertinenza dell'area tematica.

In conclusione, mentre il sistema è efficace per query con termini univoci (come *"basketball"* o *"supreme court"*), fallisce nel catturare l'intento dell'utente quando le parole chiave sono ambigue.

```
Top 5 Results for: 'basketball championship finals'
1. [Score: 0.2773] British Woman Conquers World Conkers Championship With Only 20 Minutes Of Training
2. [Score: 0.2335] Florida Basketball Player Who Collapsed During Game Is Released From Hospital
3. [Score: 0.2187] Kobe Bryant One Of 8 Finalists For Basketball Hall Of Fame
4. [Score: 0.2165] John Lewis's Final Fight For Voting Rights
5. [Score: 0.2089] Virginia State University President Takes Student Back To School In Viral Basketball Clip

Enter a query (or type 'exit' to quit): government budget deficit

Top 5 Results for: 'government budget deficit'
1. [Score: 0.3063] Trump Hits A New High-Water Mark: The Biggest Federal Deficit In 6 Years
2. [Score: 0.2933] GOP No Longer Cares About The Deficit If It Means Women Having More Babies
3. [Score: 0.2574] Democrats Consider Abandoning Budget Floor Vote
4. [Score: 0.2488] Congress, Trump Look To Put Budget Fight On Hold Until After Bush Funeral
5. [Score: 0.2465] Trump Tweets 'Tariffs Working Big Time,' U.S. Trade Deficit Jumps 7 Percent In June
```

2 Esercitazione 2: Word Clustering con Word2Vec

2.1 Strumenti Utilizzati

In questa esercitazione è stato implementato un modello di **Semantica Distribuzionale** basato sull'ipotesi che parole che compaiono in contesti simili abbiano significati simili. Lo strumento principale utilizzato è stato **Word2Vec** (libreria *Gensim*), configurato con i seguenti parametri:

- **Architettura Skip-gram (`sg=1`):** A differenza del modello CBOW, lo Skip-gram utilizza una parola centrale per predire le parole circostanti. Questa scelta è stata dettata dalla sua capacità di gestire meglio dataset di dimensioni contenute e parole rare.
- **Parametri di addestramento:** Si è scelto un `vector_size` di 100 per ottenere rappresentazioni dense ma computazionalmente gestibili, e una `window` di 5 per catturare il contesto locale.
- **Clustering e Visualizzazione:** Per analizzare lo spazio vettoriale, è stato applicato l'algoritmo **K-Means** per raggruppare i vettori simili. La dimensionalità è stata ridotta a due componenti tramite **PCA** per consentire la visualizzazione grafica.

2.2 Vantaggi e Limitazioni

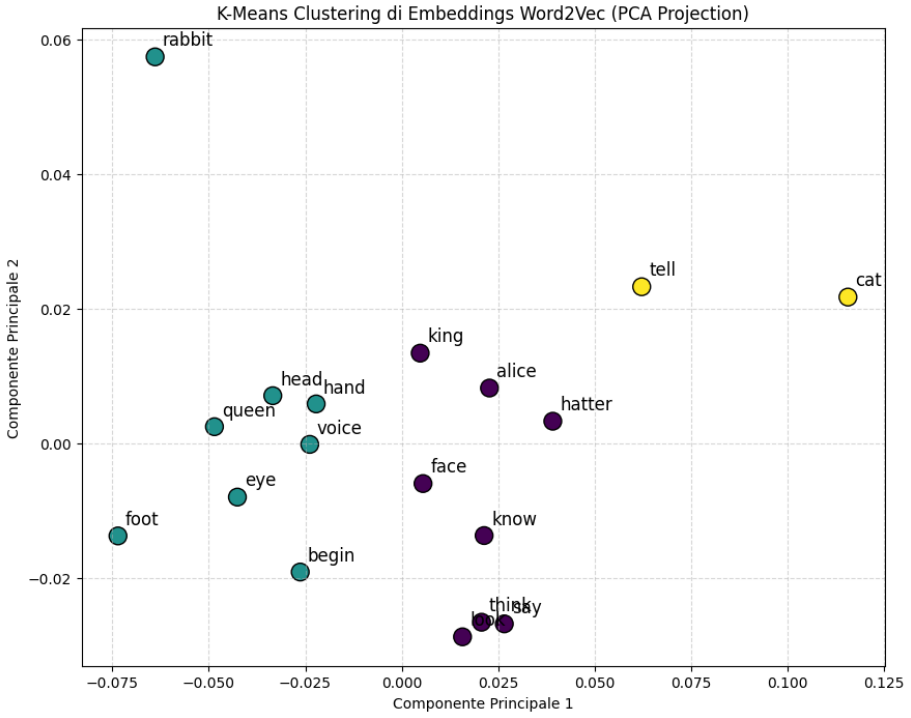
- **Vantaggi:** Il passaggio da rappresentazioni locali (one-hot) a rappresentazioni **distribuite** e dense permette di catturare relazioni semantiche

complesse e di calcolare la similarità tra termini che non condividono la stessa stringa letterale.

- **Limitazioni:** Il modello assegna un unico vettore a ciascuna parola (embeddings statici), non riuscendo quindi a risolvere il problema della polisemia all'interno della stessa frase (es. "capo" come leader o come indumento).

2.3 Discussione dei Risultati

L'applicazione del modello sul testo di *Alice in Wonderland* ha prodotto risultati significativi. Nel grafico PCA, si è osservato un raggruppamento fisico di entità appartenenti alla stessa categoria: i personaggi principali (*Alice, Rabbit, Queen*) sono risultati vicini tra loro, mentre i verbi di comunicazione (*say, tell, think*) hanno formato un cluster distinto. Questo conferma che il modello ha "appreso" autonomamente le relazioni di ruolo e categoria grammaticale senza alcuna etichettatura manuale.



3 Esercitazione 3: N-gram Language Models

3.1 Strumenti Utilizzati

L'obiettivo di questa esercitazione è stata la creazione di un **Modello Linguistico** capace di assegnare una probabilità a sequenze di parole e generare nuovo testo. Sono stati utilizzati modelli basati sulla **stima di massima verosimiglianza (MLE)** implementati con la libreria *NLTK*.

- **Assunzione di Markov:** Per semplificare il calcolo della probabilità di una frase (che richiederebbe l'applicazione della *chain rule*), il modello assume che la probabilità di una parola dipenda solo dalle $N-1$ parole precedenti.
- **Bigrammi vs Trigrammi:** Sono stati acquisiti modelli per $N = 2$ (dipendenza da una parola) e $N = 3$ (dipendenza da due parole).

3.2 Vantaggi e Limitazioni

- **Vantaggi:** Sono modelli semplici da addestrare tramite il semplice conteggio delle occorrenze (C) nel corpus: $P(w_n|w_{n-1}) = \frac{C(w_{n-1},w_n)}{C(w_{n-1})}$.
- **Limitazioni:** Il problema principale è la **sparsità dei dati**: se una sequenza di parole non è presente nel corpus originale, la sua probabilità sarà zero. Inoltre, la coerenza a lungo termine è molto scarsa a causa della finestra di memoria limitata.

3.3 Discussione dei Risultati

Confrontando la generazione di tweet tra uno stile "Politico" e uno "Tech", è emerso chiaramente come il modello catturi il dominio lessicale (es. "economy" vs "blockchain"). In merito alla dimensione di N:

1. I **bigrammi** hanno generato frasi più creative ma spesso sintatticamente fragili, poiché la memoria locale è troppo breve per mantenere la struttura della frase.
2. I **trigrammi** hanno prodotto un testo molto più fluido e simile al linguaggio naturale, ma hanno mostrato una tendenza all'*overfitting*, ripetendo spesso segmenti identici a quelli trovati nel romanzo *Moby Dick*.

4 Conclusioni

Le esercitazioni hanno permesso di analizzare l'evoluzione delle tecniche NLP: dai modelli statistici lessicali (TF-IDF) a quelli semantici densi (Word2Vec), fino alla generazione probabilistica (N-grams).

```
 GENERAZIONE MOBY DICK
Caricamento corpus Moby Dick

> Moby Dick - BIGRAMMI (Contesto corto, più caotico):
 1. ; not but still puffing the clumsy and floes ; spring , steady fumes from queequeg ?"
 2. uncommonly shaggy bark still strove to its sighs , all the voice was put good laugh aloud , the whale
 3. world declines ; meanwhile captain ahab .
 4. the noble , when , horns of the better or , they said he ' voyage ?
 5. against the lines around her head , i drew out !

> Moby Dick - TRIGRAMMI (Contesto lungo, più strutturato):
 1. day .
 2. let this old whale heave his aged bulk , and more away , i suppose thou can ' t stop
 3. it does not bear that name .
 4. but at intervals , been found at home .
 5. and fled with swift precipitancy ; a fair wind that ' s ," cried bunger , late of the ground
```