Università degli Studi di Torino

Dipartimento di Informatica



TECNOLOGIE DEL LINGUAGGIO NATURALE

Esercitazioni parte: 2

Budaes Tanaru Riccardo Gabriele

Driza Andrea

Indice

1 Esercitazione 1: Document Similarity e Retrieval (VSM) 2
1.1 Strumenti Utilizzati 2
1.2 Vantaggi e Limitazioni 2
1.3 Discussione dei Risultati 2

2 Esercitazione 2: Word Clustering con Word2Vec 4
2.1 Strumenti Utilizzati 4
2.2 Vantaggi e Limitazioni 4
2.3 Discussione dei Risultati 4

3 Esercitazione 3: N-gram Language Models 6
3.1 Strumenti Utilizzati 6
3.2 Vantaggi e Limitazioni 6
3.3 Discussione dei Risultati 6

4 Conclusioni 8

1 Esercitazione 1: Document Similarity e Retrieval (VSM)

1.1 Strumenti Utilizzati

Per questa esercitazione è stato implementato un sistema di reperimento basato sul **Vector Space Model (VSM)** utilizzando la pesatura **TF-IDF** (*Term Frequency-Inverse Document Frequency*). Il preprocessing del dataset è stato eseguito tramite la libreria **spaCy**:

- **Batch Processing:** Utilizzo di `nlp.pipe` con `batch size=256` per velocizzare l'elaborazione dei documenti.
- **Pipeline Leggera:** Esclusione dei componenti `ner` (Named Entity Recognition) e `parser` per ridurre il carico computazionale, mantenendo solo il `tagger` necessario per una corretta lemmatizzazione.

La ricerca dei documenti più rilevanti è stata calcolata tramite la **similarità coseno** tra il vettore della query e la matrice TF-IDF dei documenti.

1.2 Vantaggi e Limitazioni

- **Vantaggi:** L'approccio basato su spaCy e TF-IDF è estremamente veloce e scalabile. L'uso della lemmatizzazione permette di ricondurre diverse forme flessionali allo stesso termine (es. "sinking" e "sink"), migliorando il richiamo del sistema.
- **Limitazioni:** Il modello soffre di **gap lessicale** e incapacità di gestire la **polisemia**. Poiché il sistema si basa sul matching delle stringhe (lemmatizzate), non è in grado di distinguere tra i diversi significati di una parola se questa compare nello stesso contesto morfologico.

1.3 Discussione dei Risultati

L'ispezione dei risultati ottenuti ha confermato le limitazioni teoriche del modello Bag-of-Words e della pesatura TF-IDF:

1. **Mancanza di Composizionalità Semantica:** Per la query `"artificial intelligence breakthrough"`, il sistema ha restituito come primo risultato l'articolo *"Artificial Christmas Trees: Here's What You Should Know This Year"* (Score: 0.4402). Poiché il TF-IDF tratta i termini in modo indipendente distruggendo l'ordine delle parole, il termine "artificial" (probabilmente raro nel corpus e quindi con un alto valore di IDF) ha dominato il calcolo del punteggio, portando in cima un documento totalmente irrilevante rispetto al contesto tecnologico richiesto.

2. **Matching Lessicale vs Intento Semantico:** Nella query `"apple smartphone release"`, i risultati estratti si concentrano esclusivamente sul brand "Apple" (es. notizie su Apple TV o AirPods) senza intercettare notizie pertinenti alla release di uno "smartphone". Il sistema fallisce nel comprendere i sinonimi o i termini correlati (come "iPhone" o "debut"), limitandosi a cercare la corrispondenza esatta della stringa.

In conclusione, mentre il sistema è efficace per query con termini univoci e specifici (come *"supreme court"*), fallisce nel catturare il reale intento dell'utente quando i singoli token assumono significati diversi se isolati dal proprio n-gramma di appartenenza.

```
Top 5 Results for: 'basketball championship finals'
1. [Score: 0.2773] British Woman Conquers World Conkers Championship With Only 20 Minutes Of Training
2. [Score: 0.2335] Florida Basketball Player Who Collapsed During Game Is Released From Hospital
3. [Score: 0.2187] Kobe Bryant One Of 8 Finalists For Basketball Hall Of Fame
4. [Score: 0.2165] John Lewis's Final Fight For Voting Rights
5. [Score: 0.2089] Virginia State University President Takes Student Back To School In Viral Basketball Clip

Enter a query (or type 'exit' to quit): government budget deficit

Top 5 Results for: 'government budget deficit'
1. [Score: 0.3063] Trump Hits A New High-Water Mark: The Biggest Federal Deficit In 6 Years
2. [Score: 0.2933] GOP No Longer Cares About The Deficit If It Means Women Having More Babies
3. [Score: 0.2574] Democrats Consider Abandoning Budget Floor Vote
4. [Score: 0.2488] Congress, Trump Look To Put Budget Fight On Hold Until After Bush Funeral
5. [Score: 0.2465] Trump Tweets 'Tariffs Working Big Time,' U.S. Trade Deficit Jumps 7 Percent In June
```

2 Esercitazione 2: Word Clustering con Word2Vec

2.1 Strumenti Utilizzati

In questa esercitazione è stato implementato un modello di **Semantica Distribuzionale** basato sull'ipotesi che parole che compaiono in contesti simili abbiano significati simili. Lo strumento principale utilizzato è stato **Word2Vec** (libreria *Gensim*), configurato con i seguenti parametri:

- **Architettura Skip-gram (`sg=1`):** A differenza del modello CBOW, lo Skip-gram utilizza una parola centrale per predire le parole circostanti. Questa scelta è stata dettata dalla sua capacità di gestire meglio dataset di dimensioni contenute e parole rare.
- **Parametri di addestramento:** Si è scelto un `vector_size` di 100 per ottenere rappresentazioni dense ma computazionalmente gestibili, e una `window` di 5 per catturare il contesto locale.
- **Salvataggio del Modello:** Al termine del training, il modello è stato serializzato e salvato su disco (`model.save()`) per consentirne il riutilizzo successivo senza dover rieseguire la pipeline di preprocessing.
- **Clustering e Visualizzazione:** Per analizzare lo spazio vettoriale, è stato applicato l'algoritmo **K-Means** per raggruppare i vettori simili. La dimensionalità è stata ridotta a due componenti tramite **PCA** per consentire la visualizzazione grafica.

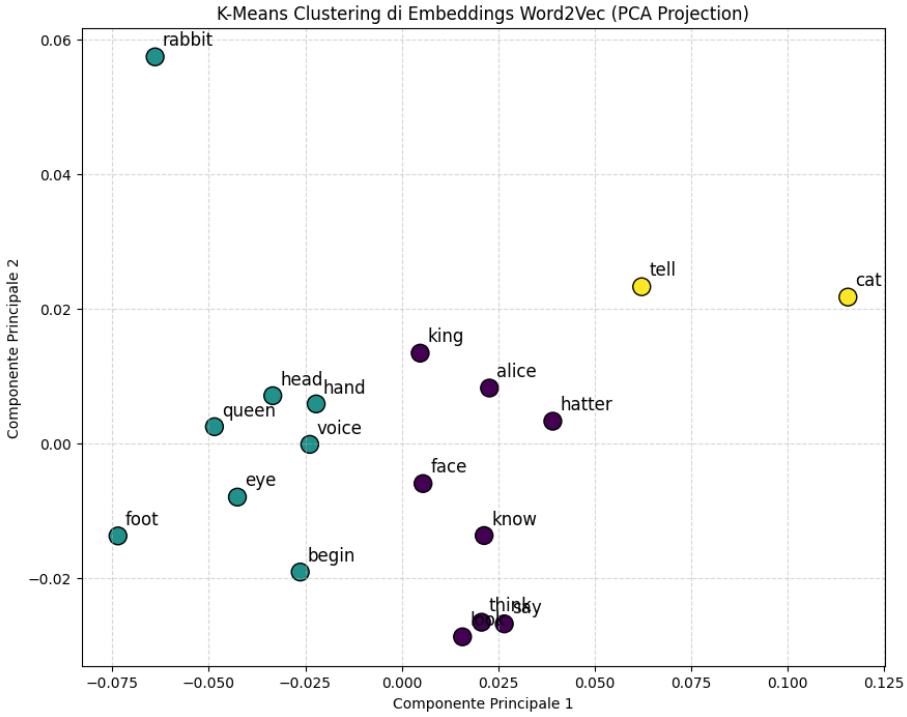
2.2 Vantaggi e Limitazioni

- **Vantaggi:** Il passaggio da rappresentazioni locali (one-hot) a rappresentazioni **distribuite** e dense permette di catturare relazioni semantiche complesse e di calcolare la similarità tra termini che non condividono la stessa stringa letterale.
- **Limitazioni:** Il modello assegna un unico vettore a ciascuna parola (embeddings statici), non riuscendo quindi a risolvere il problema della polisemia all'interno della stessa frase (es. "capo" come leader o come indumento).

2.3 Discussione dei Risultati

L'applicazione del modello sul testo di *Alice in Wonderland* ha prodotto risultati significativi. Interrogando il modello sui vicini semantici del termine *"alice"*, si nota come i primi risultati riguardino parti del corpo (*head, face*). Questo riflette l'ipotesi distribuzionale all'interno del testo specifico: Alice subisce continue trasformazioni fisiche nel romanzo, portando i termini legati al corpo a co-occorrere costantemente nella stessa finestra di contesto della protagonista. Inoltre nel grafico PCA, si è osservato un raggruppamento fisico di

entità appartenenti alla stessa categoria: i personaggi principali (*Alice, Rabbit, Queen*) sono risultati vicini tra loro, mentre i verbi di comunicazione (*say, tell, think*) hanno formato un cluster distinto. Questo conferma che il modello ha "appreso" autonomamente le relazioni di ruolo e categoria grammaticale senza alcuna etichettatura manuale.



3 Esercitazione 3: N-gram Language Models

3.1 Strumenti Utilizzati

L'obiettivo di questa esercitazione è stata la creazione di un **Modello Linguistico** capace di assegnare una probabilità a sequenze di parole e generare nuovo testo. Sono stati utilizzati modelli basati sulla **stima di massima verosimiglianza (MLE)** implementati con la libreria *NLTK*.

- **Preprocessing e Tokenizzazione:** I testi sono stati convertiti interamente in minuscolo per ridurre la sparsità del vocabolario e segmentati in token tramite la funzione `word_tokenize`.
- **Gestione dei Confini di Frase:** Per gestire correttamente le probabilità di inizio e fine delle sequenze, è stata sfruttata la funzione `padded_everygram_pipeline`, che introduce automaticamente i marcatori speciali di padding `<s>` (inizio frase) e `</s>` (fine frase).
- **Assunzione di Markov:** Per semplificare il calcolo della probabilità di una frase, il modello assume che la probabilità di una parola dipenda esclusivamente dalle $N-1$ parole precedenti.
- **Bigrammi vs Trigrammi:** Sono stati addestrati e confrontati modelli per $N = 2$ (contesto locale basato su un solo termine precedente) e $N = 3$ (contesto basato su due termini precedenti).

3.2 Vantaggi e Limitazioni

- **Vantaggi:** I modelli basati su N-grammi sono matematicamente intuitivi, estremamente veloci da addestrare e richiedono il semplice calcolo delle frequenze congiunte e marginali (C) all'interno del corpus:

$$P(w_n|w_{n-1}) = \frac{C(w_{n-1}, w_n)}{C(w_{n-1})} \tag{1}$$

- **Limitazioni:** L'utilizzo di uno stimatore MLE puro, privo di tecniche di **smoothing** (come il lisciamento di Laplace o Kneser-Ney), esaspera il problema della **sparsità dei dati (zero-probability problem)**. Se una transizione di parole non è presente nel training set, la sua probabilità crolla a zero, annullando la probabilità dell'intera frase. Inoltre, a causa della stretta finestra di memoria causata dall'assunzione di Markov, il modello è strutturalmente incapace di mantenere una coerenza sintattica e semantica a lungo termine.

3.3 Discussione dei Risultati

L'analisi del testo generato evidenzia come il modello riesca a catturare con precisione il dominio lessicale e lo stile del corpus di addestramento (es. l'uso di

termini come *"blockchain"* o *"neural"* nello stile Tech e *"country"* o *"generation"* nello stile Politico). Tuttavia, emergono variazioni strutturali al variare di N e della dimensione del dataset:

1. **Effetto della Dimensione del Corpus (Memorizzazione nei Tweet):** Nel dataset dei tweet (non di dimensioni ampie), il modello a trigrammi ha mostrato un forte fenomeno di **overfitting/memorizzazione**. Nello stile Politico, ad esempio, la sequenza generata *"today to overcome the difficult challenges of this generation ."* ricalca fedelmente e integralmente una frase del training set. Avendo a disposizione pochissimi contesti storici di lunghezza pari a 2, il modello si trova davanti a scelte probabilistiche quasi deterministiche, collassando sulla replica esatta dei dati di input.

2. **Bigrammi vs Trigrammi su Grandi Corpora come Moby Dick:** Sull'intero romanzo di Melville, dove il volume di dati riduce la rigidità ma aumenta la varietà combinatoria:

   - I **bigrammi** generano sequenze altamente caotiche e sintatticamente instabili, frammentate da un uso errato della punteggiatura (es. *"; not but still puffing the clumsy and floes ;"*). La memoria limitata a un solo token causa continui e repentini cambi di direzione sintattica.
   - I **trigrammi** mantengono una coerenza strutturale locale decisamente superiore, arrivando a produrre frasi del tutto corrette dal punto di vista grammaticale (es. *"it does not bear that name ."*), pur non potendo garantire una continuità logica globale sulla lunga distanza.

```
 GENERAZIONE MOBY DICK
Caricamento corpus Moby Dick

> Moby Dick - BIGRAMMI (Contesto corto, più caotico):
 1. ; not but still puffing the clumsy and floes ; spring , steady fumes from queequeg ?"
 2. uncommonly shaggy bark still strove to its sighs , all the voice was put good laugh aloud , the whale
 3. world declines ; meanwhile captain ahab .
 4. the noble , when , horns of the better or , they said he ' voyage ?
 5. against the lines around her head , i drew out !

> Moby Dick - TRIGRAMMI (Contesto lungo, più strutturato):
 1. day .
 2. let this old whale heave his aged bulk , and more away , i suppose thou can ' t stop
 3. it does not bear that name .
 4. but at intervals , been found at home .
 5. and fled with swift precipitancy ; a fair wind that ' s ," cried bunger , late of the ground
```

4 Conclusioni

Le esercitazioni hanno permesso di analizzare l'evoluzione delle tecniche NLP: dai modelli statistici lessicali (TF-IDF) a quelli semantici densi (Word2Vec), fino alla generazione probabilistica (N-grams).