Polisemia: complessità e struttura del significato

TLN 2025/2026 - PARTE III - Prof. Luigi Di Caro

Contenuti

1. Cambio di prospettiva
2. Dimensioni della polisemia
3. Embeddings e polisemia
4. Polisemia multilingue
5. Impatto computazionale
6. Conclusione

Dal problema della disambiguazione alla complessità

Paradigma classico: Word Sense Disambiguation

Data una parola e un contesto, selezionare il senso corretto:

$$(w, C) \rightarrow s_i \in \{s_1, s_2, \ldots, s_n\}$$

Esempio: "La *banca* è chiusa" $\rightarrow$ istituto finanziario

Limiti di questo approccio

- Assume sensi discreti e mutuamente esclusivi
- Tratta tutti i sensi come ugualmente difficili
- Ignora la complessità intrinseca della parola
- Non spiega perché alcune parole sono più difficili

Osservazione empirica

Performance WSD su parole diverse

- *cat* (gatto): accuratezza $\sim$95%
- *paper* (carta/articolo): accuratezza $\sim$81%
- *run* (correre/gestire/...): accuratezza $\sim$64%

Domanda cruciale

Questa differenza è dovuta a:

- ✓ Proprietà intrinseche delle parole?
- ✓ Complessità della loro struttura semantica?
- × Solo artefatti dei dati di training?

Idea centrale della lezione

Tesi fondamentale

La polisemia non è solo ambiguità da risolvere, ma una **struttura complessa del significato** caratterizzata da proprietà misurabili.

Implicazioni

- Alcune parole sono intrinsecamente più difficili da disambiguare
- La difficoltà dipende da proprietà quantificabili (entropia, distanza semantica, distribuzione)
- Queste proprietà influenzano direttamente le performance NLP
- La complessità varia sistematicamente tra lingue

Da classificazione a caratterizzazione

Una proprietà multidimensionale

Tre dimensioni fondamentali (McCarthy, Boleda, Mickus)

1. **Numero di sensi** (Polysemy Degree): $N(w)$
2. **Distribuzione dei sensi** (Sense Entropy): $H(w)$
3. **Separabilità semantica** (Semantic Distinctiveness): $d(s_i, s_j)$

Idea chiave

Non basta dire "quanti sensi ha una parola":

- Serve capire **come** questi sensi sono distribuiti nell'uso
- Serve misurare **quanto** sono distinguibili semanticamente
- La complessità emerge dall'interazione delle tre dimensioni

Dimensione 1: Numero di sensi

Definizione

$$N(w) = |\{s_1, s_2, \ldots, s_n\}|$$

Esempi

- *giraffa*: 1 senso (quasi monosemica)
- *banco*: 3 sensi principali
- *run* (EN): 117 sensi in WordNet 3.0!
- *set* (EN): 200+ definizioni (OED)

Limiti critici

- Dipende dalla granularità del dizionario
- Ignora la frequenza d'uso reale
- Non predice la difficoltà di disambiguazione
- Effetto corpus: corpora più grandi rivelano sensi rari

Dimensione 2: Distribuzione dei sensi

Due parole, stesso numero di sensi, complessità diversa

- **Parola A** (*school*): 95% "scuola" / 5% "banco di pesci"
- **Parola B** (*bank*): 55% "banca" / 45% "riva del fiume"

Misura: Entropia di Shannon

$$H(w) = -\sum_{i=1}^{n} p(s_i|w) \log_2 p(s_i|w)$$

- $H(w) = 0$: monosemica effettiva (un senso con $p = 1$)
- $H(w) = \log_2(n)$: massima entropia (tutti i sensi equiprobabili)
- Bassa entropia $\rightarrow$ senso dominante, disambiguazione facile
- Alta entropia $\rightarrow$ sensi bilanciati, ambiguità reale

Interpretazione operativa dell'entropia

Dati empirici (British National Corpus)

Parola	N sensi	H(w)	Interp.
school	2	0.29	Quasi mono
bank	2	0.99	Molto ambigua
paper	3	1.30	Moderata
run	5 (top)	2.15	Alta complessità

Insight critico

bank (2 sensi) ha entropia **maggiore** di **paper** (3 sensi)!

Il numero di sensi **non predice** la complessità effettiva.

Ciò che conta non è quanti sensi esistono, ma quanto sono distribuiti

Dimensione 3: Separabilità semantica

Terza dimensione fondamentale

Quanto i sensi sono distinguibili nello spazio semantico?

$$d(s_i, s_j) = \|\text{centroid}(V_i) - \text{centroid}(V_j)\|$$

Sensi ben distinti

- **bass**: pesce vs strumento musicale
  - → Distanza $\sim$3.2 (ortogonali)
  - → Omonomia più che polisemia
- **bank**: banca vs riva
  - → Distanza $\sim$2.1
  - → Polisemia genuina

Sensi graduali/sovrapposti

- **paper**: materiale → articolo
  - → Distanza $\sim$1.3
  - → Continuum metonimico
  - → Confini sfumati
- **chicken**: animale vs carne
  - → Alternanza regolare
  - → Pattern produttivo

Modelli generativi di polisemia (Pustejovsky 1995)

Generative Lexicon: polisemia regolare e prevedibile

Certi tipi di polisemia sono generati da meccanismi cognitivi sistematici:

Dot objects

book: oggetto fisico • contenuto
"Ho **comprato** il libro" (fisico)
"Ho **letto** il libro" (contenuto)

Container-content

bottiglia: contenitore • liquido
"Compro una bottiglia" (vuota)
"Bevo una bottiglia" (contenuto)

Process-result coercion

costruzione: processo • risultato
"La costruzione **durerà** 2 anni"
"La costruzione è **imponente**"

Animal-meat (grinding)

Pattern produttivo:
chicken, cow/beef, pig/pork
Esteso sistematicamente a molti animali

Dagli embeddings statici a quelli contestuali

Evoluzione storica della rappresentazione

- **Word2Vec/GloVe (2013-2014)**: un vettore statico per parola
  - → Polisemia "mediata" in un unico punto
  - → *bank* = media pesata di contesti finanziari e geografici
- **Sense embeddings (2015-2017)**: vettori multipli per senso
  - → Separazione esplicita (AdaGram, context2vec)
  - → Richiede annotazioni supervisionate
- **ELMo/BERT/GPT (2018-oggi)**: embeddings contestuali
  - → Un vettore diverso per ogni occorrenza
  - → Polisemia come proprietà emergente

$$V(w) = \{v_1, v_2, \ldots, v_m\} \quad \text{dove } v_i = \text{BERT}(w, C_i)$$

Polisemia come distribuzione vettoriale

Conseguenza fondamentale

La polisemia diventa una **distribuzione nello spazio vettoriale**

Caratterizzazione tramite clustering

Dato $V(w) = \{v_1, v_2, \ldots, v_m\}$ (embeddings contestuali):

- **Numero di cluster**: k-means $\rightarrow$ approssima numero di sensi distinguibili
- **Silhouette score**: quanto i cluster sono ben separati (alto) vs sovrapposti (basso)
- **Dispersione intra-cluster**: variabilità contestuale di ciascun senso

Pattern osservabili

- Parole semplici $\rightarrow$ cluster unico e compatto

Cluster semantici: esempi concreti

Cluster separati

bass (omonomia):

- 2 cluster netti
- Distanza euclidea $\sim$3.2
- Silhouette $>$0.7

bank (polisemia):

- 2 cluster distinguibili
- Sovrapposizione parziale

Cluster sovrapposti

paper (continuum):

- Cluster non netti
- Silhouette $\sim$0.3 (basso)
- Gradiente semantico

cat (quasi-monosemia):

- 1 cluster compatto
- Varianza intra-cluster bassa

Misura di separabilità

$$d(s_i, s_j) = 1 - \cos(\vec{\mu}_i, \vec{\mu}_j) \quad \text{dove } \vec{\mu}_i = \text{centroid}(V_i)$$

Tecniche di visualizzazione

Riduzione dimensionale per analisi qualitativa

Da 768/1024 dimensioni (BERT) a 2D:

PCA

- Preserva varianza globale
- Lineare
- Perde struttura locale

t-SNE

- Ottimo per cluster
- Distorce distanze globali
- Computazionalmente costoso

UMAP

- Bilanciamento locale/globale
- Più efficiente di t-SNE
- Preserva topologia

Non universalità della polisemia

Tesi centrale

Le lingue "ritagliano" lo spazio semantico in modi radicalmente diversi

Asimmetrie lessicali: casi emblematici

- **EN** *bank* (1 parola) $\leftrightarrow$ **IT** *banca* / *riva* (2 parole)
- **EN** *know* (1 parola) $\leftrightarrow$ **IT** *sapere* / *conoscere* (2 parole)
- **EN** *wood* (1 parola) $\leftrightarrow$ **IT** *legno* / *bosco* (2 parole)
- **RU** *ruka* (1 parola) $\leftrightarrow$ **IT** *mano* / *braccio* (2 parole)
- **JP** */ aoi* (1 parola) $\leftrightarrow$ **IT** *blu* / *verde* (2 parole)

Non esiste una corrispondenza 1:1 tra parole

Tipologia della polisemia: universale vs language-specific

Pattern (quasi-)universali

Attestati in >100 lingue:

MANO → BRACCIO
Espansione parte-tutto

VEDERE → SAPERE
Metafora concettuale

GIORNO → SOLE
Metonimia temporale

Pattern language-specific

Idiosincratici:

Russo ruka
Mano + braccio (insieme anatomico)

Giapponese aoi
Blu + verde (colori freddi)

Indonesiano makan
Mangiare + fumare + consumare

Riferimenti: Haspelmath 2003, François 2008

Studi tipologici su larga scala rivelano tensione tra universalità cognitiva e relativismo linguistico

Implicazioni per NLP multilingue

Problemi sistematici nelle applicazioni cross-linguali

Machine Translation

- **Ambiguità source**: EN *bank* → IT *banca* o *riva*?
- **Split lessicale target**: EN *know* deve disambiguarsi in IT anche se monosemico in EN
- **Granularità asimmetrica**: JP richiede informazioni extra-linguistiche

Altri task critici

- **Cross-lingual embeddings**: allineare spazi quando mapping non è 1:1
- **Multilingual BERT**: deve imparare che *bank_EN* → *banca_IT* o *riva_IT*
- **Zero-shot transfer**: performance degradate quando polisemia varia

La polisemia è un fenomeno language-specific, non universale

Polisemia e performance WSD

Risultato empirico chiave (McCarthy 2004, Navigli & Ponzetto 2012)

L'accuratezza WSD è **inversamente correlata** all'entropia dei sensi

Dati sperimentali

Parola	H(w)	WSD Acc.	MFS
school	0.29	94.2%	95.0%
bank	0.99	87.5%	55.0%
paper	1.30	81.3%	60.0%
run	2.15	63.7%	40.0%

MFS = Most Frequent Sense baseline

Conclusione

- Bassa entropia $\rightarrow$ alta accuratezza
- Alta entropia $\rightarrow$ difficile
- La complessità polisemica è **predittiva** della difficoltà

La difficoltà non è solo nel modello, ma nella parola stessa

Dataset bias: il problema della sottorappresentazione

Analisi di SemEval/Senseval (Raganato et al. 2017)

I dataset WSD standard hanno bias sistematici:

Distribuzione skewed

- $\sim$70% parole: $H(w) < 1.0$
- $<$5% parole: $H(w) > 2.0$
- Dominanza di sostantivi
- Verbi sottorappresentati

Conseguenze

- Sovrastima accuratezza modelli
- Performance reali $\ll$ benchmark
- Generalizzazione limitata
- Casi difficili ignorati

Soluzione: stratified sampling

- Campionare uniformemente da 5 fasce di entropia: [$<$0.5, 0.5-1.0, 1.0-1.5, 1.5-2.0, $>$2.0]

Polisemia come struttura cognitiva

Tesi (Lakoff & Johnson 1980, Pustejovsky 1995)

La polisemia non è rumore casuale, ma struttura semantica motivata da principi cognitivi sistematici

Metafora concettuale

- **TEMPO È SPAZIO**: *lungo discorso, breve pausa*
- **CAPIRE È AFFERRARE**: *cogliere un'idea*
- **ARGOMENTO È GUERRA**: *attaccare una tesi*

Catene radiali

head (inglese):

- Parte corpo (prototipo)
- Head of nail (somiglianza fisica)
- Head of table (verticalità)
- Head of dept (metafora CONTROLLO È SU)

LLM e polisemia: successi e limiti

Successi

- **Adattamento contestuale**: self-attention pesa token rilevanti per ogni senso
- **Rappresentazione dinamica**: ogni layer raffina verso senso corretto
- **Cattura implicita**: apprendono distribuzioni senza annotazioni esplicite
- **Performance elevate**: SOTA su WSD, MT, QA

Limiti persistenti

- **Sensi rari**: sotto-rappresentati in training $\rightarrow$ performance degradate
- **Sensi simili**: sfumature sottili richiedono conoscenza del mondo profonda
- **Neologismi polisemici**: *viral* (social media) non presente in training
- **Interpretabilità**: non è chiaro se "capiscono" o approssimano pattern

Applicazioni downstream

La polisemia influenza molti task NLP

Text Simplification

- Identificare termini advanced
- Sostituire con equivalenti basic
- Parole ad alta entropia più difficili da semplificare

Summarization

- Privilegiare sensi frequenti
- Evitare ambiguità in riassunti brevi

Question Answering

- Disambiguare query
- Tracking sensi in reasoning
- Risposte adattate al livello utente

Information Retrieval

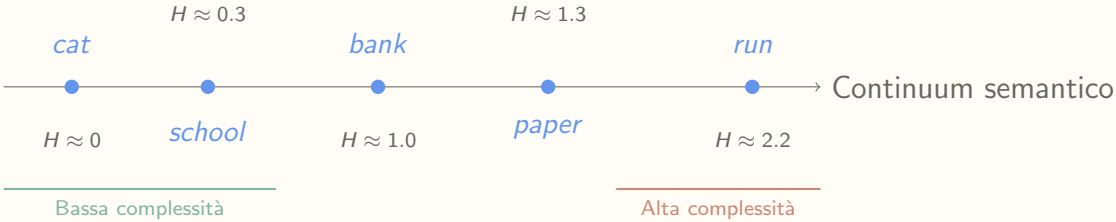
- Query expansion considerando sensi
- Ranking sensibile a polisemia
- Diversification dei risultati

Takeaways principali

Cosa abbiamo imparato

1. **Polisemia = fenomeno multidimensionale**: numero sensi + distribuzione + separabilità
2. **Entropia fondamentale**: predice difficoltà WSD meglio del semplice conteggio sensi
3. **Embeddings contestuali rivelano struttura**: cluster nello spazio vettoriale
4. **Variazione cross-linguistica**: non universalità, asimmetrie lessicali sistematiche
5. **Impatto diretto su NLP**: WSD, MT, simplification, summarization, QA
6. **Struttura cognitiva**: metafora, metonimia, catene radiali (non rumore casuale)

Dal discreto al continuo



La polisemia non è binaria: è un gradiente

Domande aperte e direzioni future

Domande teoriche

- Molti sensi = più complessità? (No: dipende dalla distribuzione)
- Discreto vs continuo? (Entrambi: dipende dalla scala)
- LLM rappresentano davvero i sensi?

Direzioni future

- Polisemia dinamica: tracking evoluzione temporale
- Context-dependent basicness
- Multilingualità su larga scala
- Integrazione esplicita in LLM

Sfide aperte

- Come modellare sensi rari ma importanti?
- Come integrare conoscenza cognitiva?
- Come costruire dataset bilanciati per complessità?

Laboratorio LAB-3

A scelta tra...

1. **Analisi quantitativa**: Ad es. calcolare $H(w)$ per 1000 parole da SemCor, correlare con performance WSD
2. **Visualizzazione**: Ad es. clustering BERT embeddings per 10 parole con diversa complessità, UMAP projection
3. **Cross-linguale**: Ad es. confrontare polisemia EN-IT su 50 coppie da BabelNet
4. **LLM errors**: Ad es. testare sistema WSD o LLM su parole ad alta vs bassa entropia, misurare correlazione accuracy$\sim$H(w)
5. **Benchmark design**: Costruire dataset WSD stratificato per quintili di entropia

Maggiori materiali e riferimenti sulle dispense