1 PoS Tagger

Costruire un PoS tagger statistico basato su HMM per il Greco antico e il Latino

A. Implementare Learning (contare) e Decoding (Viterbi)
B. Addestrare il sistema su Greco e Latino (separatamente) usando 2 Treebank del progetto UD
C. Valutare il sistema, usando diverse strategie di smoothing
D. Valutare rispetto ad una baseline facile e ad una difficile

1.A algoritmo per il learning

- Elenchi di parole e di PoS TAG
- Probabilità PoS->PoS: **$P(t_i|t_{i-1})$** $$P(t_i|t_{i-1}) = \frac{C(t_{i-1}, t_i)}{C(t_{i-1})}$$
- Probabilità PoS->Word: **$P(w_i|t_i)$** $$P(w_i|t_i) = \frac{C(t_i, w_i)}{C(t_i)}$$
- Viterbi
- **HINT**: usare i logaritmi per le probabilità!

1.A algoritmo per il learning

- Elenchi di parole e di PoS TAG

```
# sent_id = test-s1
# text = + In Dei omnipotentis nomine, regnante domno nostro Karolus divina faventem clementia imperatore augu
quinta.
# reference = document_id='85:47'-span='146'
1       +       +       PUNCT   SYM     _       5       punct   _       _
2       In      in      ADP     r|r|-|-|-|-|-|-|-       _       5       case    _       _
3       Dei     Deus    PROPN   Propn|n|-|s|-|-|-|m|g|- Case=Gen|Gender=Masc|Number=Sing        5       nmod
4       omnipotentis    omnipotens      ADJ     a|a|-|s|-|-|-|m|g|-     Case=Gen|Gender=Masc|Number=Sing
5       nomine  nomen   NOUN    n|n|-|s|-|-|-|n|b|-     Case=Abl|Gender=Neut|Number=Sing        7       obl
...       ...             ...
```

```
# newdoc id = tlg0003.tlg001.perseus-grc1.1.tb.xml
# sent_id = tlg0003.tlg001.perseus-grc1.1.tb.xml@3
# text = τὰ γὰρ πρὸ αὐτῶν καὶ τὰ ἔτι παλαίτερα σαφῶς μὲν εὑρεῖν διὰ χρόνου πλῆθος ἀδύνατα ἦν, ἐκ δὲ τεκμηρίων ὧν ἐπὶ
νομίζω γενέσθαι οὔτε κατὰ τοὺς πολέμους οὔτε ἐς τὰ ἄλλα.
1       τὰ      ὁ       DET     l-p---na-       Case=Acc|Gender=Neut|Number=Plur        11      det     _       _
2       γὰρ     γάρ     ADV     d--------       _       15      advmod  _       _
3       πρὸ     πρό     ADP     r--------       _       4       case    _       _
4       αὐτῶν   αὐτός   PRON    p-p---ng-       Case=Gen|Gender=Neut|Number=Plur        1       nmod    _       _
5       καὶ     καί     CCONJ   c--------       _       1       cc      _       _
6       τὰ      ὁ       DET     l-p---na-       Case=Acc|Gender=Neut|Number=Plur        8       det     _       _
7       ἔτι     ἔτι     ADV     d--------       _       8       advmod  _       _
...       ...             ...
```

1.B data: training-dev-test

- Greco antico -> Perseus
  - INFO: https://universaldependencies.org/treebanks/grc_perseus/index.html
  - DATA: https://github.com/UniversalDependencies/UD_Ancient_Greek-Perseus
- Latino -> LLCT
  - INFO: https://universaldependencies.org/treebanks/la_llct/index.html
  - DATA: https://github.com/UniversalDependencies/UD_Latin-LLCT

1.C smoothing

Ipotesi di smoothing per le parole sconosciute:

- Sempre nomi P(unk|NOUN) = 1
- Sempre nomi/verbi P(unk|NOUN)=P(unk|VERB)=0.5
- $P(unk|t_i) = 1/\#(PoS_TAGs)$
- Statistica PoS sul development set: parole che compaiono 1 sola volta
- Approcci Syntax-based? Suffissi? (opzionale)

1.D Valutare

Calcolare la precisione sul test set.

Implementare 2 baselines:

- Facile: assegnare il tag più frequente se c'è nel training, altrimenti nome.
- Difficile (opzionale): MEMM https://github.com/Michael-Tu/ML-DL-NLP/tree/master/MEMM-POS-Tagger

Quali sono gli errori più comuni?